

Evaluatiekader voor Lokale Taalmodellen

Verslag door Steven Heijn
September 2026



Student: Steven Heijn
Studie: Minor - Future-proof met AI
Datum: 29-09-2026



Inhoudsopgave

1. Doelstelling.....	2
2. Vergelijking: Externe Cloud servers ten opzichte van Lokale Uitvoering.....	2
3. Data-opslag en Dataminimalisatie.....	3
4. Controle van Open-Source Licenties op Hugging Face.....	3
5. Hardwarecapaciteit en Modelgrootte op een Laptop.....	4
6. Besliskader: Wanneer is Lokaal Draaien Nodig?.....	4

1. Doelstelling

Dit document helpt bepalen of het nodig en mogelijk is om een open-source taalmodel lokaal op een laptop te draaien. Daarbij worden privacy, licenties en de technische mogelijkheden van de computer overzichtelijk op een rij gezet.

2. Vergelijking: Externe Cloud servers ten opzichte van Lokale Uitvoering

Werken met externe API's is heel anders dan programma's lokaal draaien, met name op het gebied van databeheer en beveiliging.

Beveiligingsaspect	Externe Cloudserver (API)	Lokaal Draaien (Laptop)
Datatransport	Gegevens verlaten het apparaat via internetverbindingen naar externe datacenters.	Promptverwerking vindt intern plaats via het geheugen van de laptop; geen uitgaand dataverkeer.
Opslag en logging	Aanbieders hanteren eigen retentiebeleid voor verzoeken en systeemdiagnostiek.	Volledige controle over tijdelijke caches, sessiegeschiedenis en schijfopslag.

Beveiligingsaspect	Externe Cloudserver (API)	Lokaal Draaien (Laptop)
Hergebruik van data	Sommige diensten gebruiken invoerdata voor modelverbetering, tenzij expliciet uitgeschakeld.	Invoerdata kan technisch niet door externe partijen worden benut voor trainingsdoeleinden.
Juridische jurisdictie	Vaak onderhevig aan wetgeving buiten de EU (zoals de US CLOUD Act).	Blijft binnen het lokale beheer van de organisatie of gebruiker (AVG-conformiteit vereenvoudigd).
Beveiligingsfocus	Afhankelijk van het beveiligingsniveau en certificeringen van de externe leverancier.	Afhankelijk van de fysieke beveiliging en endpoint-beveiliging van het eigen apparaat.

3. Data-opslag en Dataminimalisatie

Volgens de privacywet (AVG) mogen er niet meer persoonsgegevens worden gebruikt dan strikt noodzakelijk, en uitsluitend voor het vooraf bepaalde doel.

- **Alleen noodzakelijke gegevens invoeren:** Door modellen lokaal op een eigen computer te draaien, komen achtergrondgegevens (zoals IP-adressen en tijdstempels) niet bij externe bedrijven terecht. Toch blijft het van belang om alleen informatie in te voeren die echt nodig is voor de specifieke taak.
- **Opgeslagen geschiedenis opruimen:** Programma's zoals Ollama of LM Studio slaan eerdere vragen en antwoorden vaak standaard op in logbestanden. Om aan de privacyregels te voldoen, moeten deze automatische logs worden uitgezet of regelmatig worden gewist.
- **Beveiliging van het apparaat:** Bestanden op een laptop lopen risico bij diefstal of toegang door onbevoegden. Schijfversleuteling (zoals BitLocker of FileVault) en een goede inlogbeveiliging zijn noodzakelijk om datalekken te voorkomen.

4. Controle van Open-Source Licenties op Hugging Face

Modellen op Hugging Face zijn lang niet altijd vrij te gebruiken. Het is daarom belangrijk om voor de start van een project altijd de voorwaarden te controleren in het overzicht (de README.md) en het LICENSE-bestand.

1. **Vrije (permissieve) licenties (zoals Apache 2.0 of MIT):**
 - Bieden volledige ruimte voor onderzoek, intern gebruik én commerciële toepassingen.
 - Vragen om minimale verplichtingen, vooral bronvermelding en het behoud van de originele licentietekst.
2. **Beperkte licenties voor open modellen (zoals Meta Llama of Qwen Community):**
 - Gelden officieel niet als open source volgens de normen van het Open Source Initiative (OSI).
 - Stellen vaak duidelijke gedragsregels (Acceptable Use Policies) of commerciële grenzen, zoals een maximumaantal actieve gebruikers per maand.
3. **OpenRAIL-licenties (voor verantwoord AI-gebruik):**
 - Sluiten specifieke toepassingen expliciet uit, zoals het stellen van medische diagnoses of automatische besluitvorming zonder menselijke controle.

Het is raadzaam om vóór ingebruikname altijd de **license**-tag op de modelkaart te vergelijken met de daadwerkelijke tekst in het licentiebestand; makers vullen deze gegevens op Hugging Face namelijk niet altijd compleet of foutloos in.

5. Hardwarecapaciteit en Modelgrootte op een Laptop

Een standaard laptop heeft vaak een beperkte hoeveelheid werkgeheugen (RAM) en grafisch geheugen (VRAM). Dit bepaalt hoe zwaar een AI-model mag zijn:

- **Kleine modellen (3 tot 4 miljard parameters, bijv. Llama 3.2 3B, Phi-3.5):**
Hebben ongeveer 4 tot 6 GB geheugen nodig (bij gangbare 4-bit compressie/GGUF). Dit werkt vlot op vrijwel elke recente laptop en volstaat prima voor basistaken zoals samenvatten of gegevens uit tekst halen.
- **Middelgrote modellen (7 tot 8 miljard parameters):**
Vragen minstens 8 tot 12 GB vrij geheugen. Deze modellen redeneren een stuk beter en volgen instructies nauwkeuriger op, maar vragen ook merkbaar meer van de processor en de batterij.
- **Grote modellen (14 miljard parameters en hoger):**
Vragen aanzienlijk meer geheugen en rekenkracht. Met een laptop uitgerust met bijvoorbeeld een AMD Ryzen AI 7 350, 32 GB LPDDR5x RAM en een AMD XDNA 2 NPU is er echter voldoende capaciteit aanwezig om een 14B-model (zoals qwen2.5-coder:14b) soepel en efficiënt lokaal te laten draaien.

6. Besliskader: Wanneer is Lokaal Draaien Nodig?

Lokaal draaien is verstandig of zelfs noodzakelijk bij de volgende situaties:

- **Gevoelige persoonsgegevens:** Er wordt gewerkt met privacygevoelige data (zoals medische, juridische of strafrechtelijke gegevens) die volgens beleid of wetgeving binnen het eigen netwerk moet blijven.
- **Geheimhouding en bedrijfsgeheimen:** Er geldt een geheimhoudingsverklaring (NDA) of het betreft waardevolle bedrijfsinformatie en intellectueel eigendom.
- **Geen stabiel internet:** De software moet functioneren op afgeschermdes locaties of plekken zonder betrouwbare internetverbinding.

Een externe cloud-API werkt daarentegen beter wanneer:

- **Complexe taken:** Er zijn zware analyses nodig die alleen de allergrootste AI-modellen kunnen uitvoeren.
- **Bepaalde hardware:** De computer beschikt over onvoldoende rekenkracht, waardoor taken te lang duren of het apparaat oververhit raakt.
- **Openbare data:** Er wordt uitsluitend gewerkt met publieke bronnen, zonder risico dat vertrouwelijke gegevens uitlekken.

De keuze voor een lokaal model is een afweging tussen privacy en de rekenkracht van de apparatuur. In veel zakelijke situaties biedt een compact, geoptimaliseerd model (zoals een 7B- of 8B-model met een open Apache 2.0-licentie) de beste balans tussen wetgeving en praktische prestaties.

Praktijkvoorbeeld: Voor taken met gevoelige broncode of vertrouwelijke documenten biedt het lokaal draaien van *qwen2.5-coder:14b* op een krachtige laptop (32 GB RAM) een uitstekende oplossing. Mocht er behoefte zijn aan een alternatief voor algemenere taken, dan geldt *gemma 4 32k* als een sterke runner-up.